

Appunti del corso di Probabilità e Statistica

UniVR - Dipartimento di Informatica
secondo semestre - A.A. 2025/26

Mattia Nicolis

Matteo Drago

Indice

1	Introduzione	1
1.1	Raccolta dati e statistica descrittiva	1
1.2	Inferenza statistica e modelli probabilistici	2
1.3	Popolazioni e campioni	2
2	Distribuzioni di frequenze	4
2.1	Distribuzioni di frequenze: classi	4
2.1.1	Istogramma	5
2.1.2	Diagramma a barre	6
2.2	Frequenze cumulate e loro rappresentazione	7
3	Indici di posizione e dispersione	9
3.1	Indici di posizione	9
3.1.1	Media	9
3.1.2	Mediana, quatrili e percentili	10
3.1.3	Moda	11
3.2	Indici di dispersione	12
3.2.1	Varianza e scarto quadratico medio	12
3.3	Campioni normali	13
4	Correlazione tra variabili e regressione lineare	15
4.1	Correlazione tra variabili	15
4.2	Regressione lineare	16
5	Calcolo combinatorio	17
5.1	Permutazione	17
5.2	Disposizione	18
5.3	Combinazione	20
6	Probabilità	21
6.1	Probabilità non condizionata	21
6.2	Probabilità condizionata	23
7	Variabili aleatorie	25
7.1	Variabili aleatorie finite	26
8	Laboratorio	28

8.1	Introduzione ad R	28
8.1.1	Pacchetti importanti	28
8.2	Primi comandi	28
8.2.1	Cronologia dei comandi	29
8.2.2	Ottenere aiuto (help)	29
8.3	Variabili semplici	29
8.3.1	Assegnazione, Sovrascrittura, Rimozione	30
8.4	Vettori	30
8.4.1	Ripetizioni di vettori	31
8.4.2	Funzioni utili per i vettori	31
8.5	Matrici	31
8.5.1	Matrici speciali	32
8.5.2	Operazioni con vettori e matrici	33
8.5.3	Funzioni utili per le matrici	34
8.6	Caratteri	34
8.6.1	Funzioni utili	35
8.7	Liste, Array e Data Frame	35
8.7.1	Liste	35
8.7.2	Array	35
8.7.3	Data-Frame	36
8.8	Fattori	37
8.8.1	Strutture if, else	37
8.8.2	Struttura for, while	37
8.9	Rappresentazione Grafica	38
8.9.1	Grafico a Barre	39
8.9.2	Line Plot	39
8.9.3	Istogramma	39
8.9.4	BoxPlot	40
8.9.5	Mostrare più grafici contemporaneamente	40
8.9.6	Salvare ed esportare grafici	41
8.10	Salvare e caricare	41
8.10.1	variabili	41
8.10.2	Dati Tabulari	42
8.11	File.R - script e funzioni	42
8.11.1	Variabili locali e gloabali	42
8.12	Statistica Descrittiva	43
8.12.1	Funzioni comuni	43
8.12.2	Dataset PalmerPenguins	44

Introduzione

La **statistica** si occupa della **raccolta dati, nella loro descrizione e analisi**, guidandoci nel trarre le conclusioni.

1.1 Raccolta dati e statistica descrittiva

La statistica permette di descrivere, sintetizzare e analizzare dati presi da un campione di dati definito.

Altre volte, il lavoro dello statistico inizia prima che i dati siano stati ottenuti e il suo primo obiettivo consiste nell'ideare un procedimento ottimale per la loro raccolta.

Esempio: indagine statistica

Immaginiamo che un docente voglia determinare quale sia il più efficace tra due diversi metodi per insegnare la programmazione a dei neofiti.

Un possibile approccio potrebbe essere:

1. dividere gli studenti in due gruppi
2. usare un metodo didattico per ciascun gruppo

Alla fine del corso gli studenti vengono esaminati e i punteggi dei membri dei due gruppi vengono confrontati.

Se i risultati di uno dei due gruppi risultassero notevolmente più alti, sarebbe ragionevole pensare che il corrispondente metodo di insegnamento sia migliore.

È importante notare che per poter trarre delle conclusioni valide dei dati è essenziale che gli studenti siano divisi in modo che in nessuno dei due gruppi si vengano a trovare elementi con una maggiore predisposizione alla programmazione.

Il metodo accettato per superare questo problema consiste nel dividere "a caso" gli studenti in due gruppi.

A esperimento concluso, i dati devono essere raccolti e commentati.

La parte della **statistica che si occupa di illustrare e sintetizzare i dati** è chiamata **statistica descrittiva**.

1.2 Inferenza statistica e modelli probabilistici

Considerando l'esempio fatto in precedenza, dopo che la prova si è conclusa e i dati sono stati illustrati e sintetizzati, vorremmo poter trarre una conclusione su quale dei due metodi di insegnamento sia superiore.

La parte della statistica che si occupa di questo aspetto è detta **inferenza statistica**.

Per dedurre enuncii formalmente validi dai dati raccolti, è necessario prendere in considerazione l'influenza del caso.

Esempio: indagine statistica

Potrebbe accadere che il punteggio medio dei membri del primo gruppo sia superiore, ma di poco, a quello del secondo gruppo.

È corretto concludere che questa differenza sia dovuta al metodo didattico utilizzato?

È possibile che sia una casualità?

Per poter giungere a conclusioni pienamente giustificate è necessario fare alcune assunzioni sulla probabilità che i dati che vengono misurati assumano diversi valori possibili.

L'**insieme di queste ipotesi** è detto **modello probabilistico** per i dati.

A volte la natura dei dati suggerisce la forma del modello probabilistico da adottare.

Esempio: indagine statistica

Consideriamo un ingegnere della produzione che vuole scoprire la frazione di circuiti integrati difettosi riscontrata con un nuovo metodo produttivo.

Egli potrebbe selezionare un certo numero di chip e testarli: il numero di quelli difettosi costituirà il dato sperimentale.

Se la scelta del campione da testare è stata fatta "a caso" è ragionevole supporre che ciascuno dei chip sarà difettoso con probabilità p , pari alla frazione incognita di chip difettosi sul totale di quelli prodotti.

In altre situazioni potrebbe non essere evidente quale sia il modello di probabilità per un certo campione di dati.

Molto spesso, un'attenta descrizione e presentazione dei dati ci permette di inferire quale sia un modello accettabile, che può eventualmente essere messo alla prova raccogliendo nuovi dati.

1.3 Popolazioni e campioni

La statistica è normalmente interessata a ottenere informazioni su un **insieme completo di oggetti** che viene detto **popolazione**.

Esso, però, è spesso troppo grande perchè sia possibile un esame esaustivo.

In questi casi, si cerca di imparare qualcosa sulle popolazioni scegliendo e poi esaminando dei

sottogruppi di loro elementi.

Un **sottogruppo della popolazione** è detto **campione**.

Siccome il campione deve contenere informazioni sulla popolazione complessiva, deve essere rappresentativo di quella popolazione.

Esempio: indagine statistica

Consideriamo di effettuare una ricerca sulla distribuzione delle età degli abitanti di un certo comune e, intervistati i primi 100 che entrano in una biblioteca, venisse trovata che l'età media è di 46.2 anni.

Possiamo concludere che questa sia l'età media dell'intera popolazione?

Probabilmente no, perchè il campione scelto non è rappresentativo della popolazione in esame, essendo gli utenti della biblioteca più facilmente studenti e anziani che non persone in età lavorativa.

Distribuzioni di frequenze

La statistica riguarda i metodi scientifici per raccogliere, ordinare, riassumere e presentare i dati, per trarre valide conclusioni ed eventualmente prendere ragionevoli decisioni sulla base di tale analisi.

Definizione: variabili alleatorie

Le variabili oggetto di osservazione statistica si classificano in due tipologie:

- ▷ **variabili numeriche:** assume solo valori numerici ($N = 0, 1, \dots$)
 - ◊ discrete: insieme dei valori che può assumere è finito o numerabile
 - ◊ continue: insieme dei valori che può assumere è l'insieme dei numeri reali $\mathbb{R}$ o un intervallo $I \subset \mathbb{R}$ ($H \in \mathbb{R}$)
- ▷ **variabili categoriche:** $C = \text{marrone, blue, verde, } \dots$

I dati che non sono stati ancora ordinati numericamente si dicono **grezzi**.

Una **serie** è un ordinamento di dati grezzi in ordine crescente/decrescente.

La differenza tra il più grande e il più piccolo si dice **campo di variazione**.

2.1 Distribuzione di frequenze: classi

Per studiare i dati a disposizione occorre costruire una **distribuzione di frequenze**: una tabella dove in una colonna si mettono i valori assunti dalla variabile e in un'altra il numero delle volte che tali valori vengono assunti (frequenze).

Esempio: istogramma

Consideriamo la variabile P peso di un gruppo di 100 studenti.

Peso in kg	Numero di studenti
$64 < P \leq 66$	5
$66 < P \leq 68$	18
$68 < P \leq 70$	42
$70 < P \leq 72$	42
$72 < P \leq 74$	8
Totale	100

Possiamo definire:

- ▷ **ampiezza** della classe: differenza tra il valore massimo e il valore minimo
- ▷ **valore centrale** della classe: semisomma degli estremi

Per rappresentare le distribuzioni di frequenze si utilizzano:

- ◇ **istogrammi**: variabili numeriche
- ◇ **diagrammi a barre**: variabili categoriche

2.1.1 Istogramma

Un **istogramma** consiste in un insieme di rettangoli adiacenti aventi base sull'asse x con:

- **punto medio** nel valore centrale della classe
- **altezza** proporzionale alla frequenza della classe
- **area** pari alla frequenza relativa/percentuale della classe

In questo modo se si sommano le aree di tutti i rettangoli ottenuti, si ottiene un valore fisso:

- ◇ 1: frequenze relative
- ◇ 100: frequenze percentuali

Esempio: diagramma a barre

Si consideri la seguente distribuzione di frequenze:

Distribuzione	Frequenze
$110 < D \leq 130$	20
$130 < D \leq 150$	40
$150 < D \leq 170$	60
$170 < D \leq 210$	80
Totale	200

Riferendoci alla tabella in questione vogliamo determinare la frequenza percentuale e costruire il relativo istogramma.

Distribuzione	Frequenze	Frequenze %
$110 < D \leq 130$	20	10%
$130 < D \leq 150$	40	20%
$150 < D \leq 170$	60	30%
$170 < D \leq 210$	80	40%
Totale	200	100%

Riportiamo sull'asse x gli estremi delle classi.

Ricordando che l'area di ogni rettangolo deve dare le frequenze percentuali, si ha:

▷ **altezza prima classe:**

$$\frac{10}{(130 - 110)} = 0.5$$

▷ **altezza seconda classe:**

$$\frac{20}{(150 - 130)} = 1.0$$

▷ **altezza terza classe:**

$$\frac{30}{(170 - 150)} = 1.5$$

▷ **altezza quarta classe:**

$$\frac{40}{(210 - 170)} = 1.0$$




Figura 2.1: istogramma

2.1.2 Diagramma a barre

I **diagramma a barre** sono dei rettangoli, non allineati, in cui l'altezza rappresenta la frequenza relativa/percentuale di quella classe.

Sull'asse x si riportano i tipi, in un ordine deciso dall'osservatore stesso.

Esempio:

Consideriamo le frequenze dei colori degli occhi delle persone:

Colore occhi	Frequenze	Frequenze %
Marrone	150	50%
Blu	90	30%
Verde	30	10%
Altro	30	10%
Totale	300	100%




Figura 2.2: diagramma a barre

2.2 Frequenze cumulate e loro rappresentazione

La **frequenza cumulata** (variabili numeriche) è la **somma di tutte le frequenze inferiori o uguali al confine** di una fissata classe.

Per questo motivo le classi vengono prese aperte a sinistra e chiuse a destra.

Il grafico delle frequenze cumulate è detto **ogiva**.

Esempio: calcolo delle frequenze cumulate

Consideriamo le seguenti distribuzioni di frequenza:

Distribuzione	Frequenze
$110 < D \leq 130$	20
$130 < D \leq 150$	40
$150 < D \leq 170$	60
$170 < D \leq 210$	80
Totale	200

Riferendoci alla tabella in questione vogliamo determinare la frequenza percentuale cumulata e costruire il relativo grafico.

Distribuzione	Frequenze	Frequenze %	Frequenze cumulate %
$110 < D \leq 130$	20	10%	10%
$130 < D \leq 150$	40	20%	30%
$150 < D \leq 170$	60	30%	60%
$170 < D \leq 210$	80	40%	100%
Totale	200	100%	




Figura 2.3: gráfico a ogiva

Indici di posizione e dispersione

Al giorno d'oggi non è raro dover trattare grandi quantità di dati. Per avere una sensazione di un così vasto campione di dati, è utile saperli sintetizzare in qualche misura

3.1 Indici di posizione

Gli **indici di posizione** aiutano a capire quali sono i valori che assume una certa distribuzione con particolare attenzione al centro di questa.

3.1.1 Media

Consideriamo di avere la seguente distribuzione: N rappresenta la numerosità della popolazione, n il numero delle classi.

X	Frequenze	Frequenze relative
x_1	f_1	p_1
x_2	f_2	p_2
$\vdots$	$\vdots$	$\vdots$
x_n	f_n	p_n
Totale	N	1

Definizione: media

Si chiama **media** di X è la quantità:

$$\bar{X} = \frac{1}{N} \sum_{i=1}^n x_i \cdot f_i = \sum_{i=1}^n x_i \cdot p_i$$

Esempio: calcolo della media

Consideriamo la distribuzione di alcuni studenti.

Peso (Kg)	Frequenze	Frequenze relative
65	2	0.2
68	1	0.1
69	1	0.1
70	2	0.2
72	1	0.1
74	3	0.3
Totale	10	1.0

Si ha:

$$\bar{P} = \frac{1}{10}(65 \cdot 2 + 68 \cdot 1 + 69 \cdot 1 + 70 \cdot 2 + 72 \cdot 1 + 74 \cdot 3) = 70.1$$

3.1.2 Mediana, quatrili e percentili

Definizione: mediana

La **mediana** è il valore che provoca la ripartizione della popolazione in esame in due parti ugualmente numerose: per il 50% della popolazione il dato è minore della mediana, per il restante 50% il dato è maggiore della mediana.

Se abbiamo i dati non raggruppati, possiamo pensarli sotto forma di fila ordinata.

La mediana, allora, è:

- ▷ **valore centrale:** numeri dispari
- ▷ **media dei valori centrali:** numeri pari

Esempio: calcolo della mediana

Consideriamo il seguente campione X di numeri:

67, 72, 78, 78, 84, 85, 87, 91

Si tratta di un campione di numerosità 8 (pari):

$$Med(X) = \frac{1}{2}(78 + 84) = 81$$

Consideriamo il seguente campione X di numeri:

65, 67, 72, 78, 78, 84, 85, 87, 91

Si tratta di un campione di numerosità 9 (dispari):

$$Med(X) = 78$$

La **media e la mediana sono statistiche utili per descrivere i valori centrali dei dati.**

La media fa uso di tutti i dati e, in particolare, è influenzata in maniera sensibile dai valori eccezionalmente alti o bassi.

La mediana, invece, dipende direttamente solo da uno o due valori in centro alla distribuzione e non risente dei dati estremi.

Definizione: quartili

I **quartili** sono quei valori che ripartiscono la popolazione (ordinata), in quattro parti ugualmente numerose (ciasuna pari al 25% del totale):

- ◇ **primo quartile** (q_1): 25% della popolazione a sinistra e il 75% a destra
- ◇ **secondo quartile** (q_2): 50% della popolazione a sinistra e il 50% a destra (mediana)
- ◇ **terzo quartile** (q_3): 75% della popolazione a sinistra e il 25% a destra

Se il campione si trova sotto forma di fila ordinata $(x_1, x_2, \dots, x_N)$, allora per il calcolo si procede in modo analogo a quanto fatto per la mediana.

Se si vuole calcolare q_k si moltiplica $p = 0.k$ per la numerosità del campione N :

- se pN è intero:

$$q_k = \frac{1}{2}(x_{pN} + x_{pN+1})$$

- se pN non è un numero intero:

$$q_k = x_{\lfloor pN \rfloor + 1}$$

Esempio: calcolo dell'n-simo quartile

Consideriamo il seguente campione X di numeri:

67, 72, 78, 78, 84, 85, 87, 91

Si tratta di un campione di numerosità 8 (pari).

Quanto valgono i quartili?

- ▷ **primo quartile:** $0.25 \cdot 8 = 2$

$$q_1 = \frac{1}{2}(x_2 + x_3) = \frac{1}{2}(72 + 78) = \mathbf{75}$$

- ▷ **secondo quartile:**

$$q_2 = \text{Med}(X) = \frac{1}{2}(78 + 84) = \mathbf{81}$$

- ▷ **terzo quartile:** $0.75 \cdot 8 = 6$

$$q_3 = \frac{1}{2}(x_6 + x_7) = \frac{1}{2}(85 + 87) = \mathbf{86}$$

3.1.3 Moda**Definizione: moda**

La **moda** di un insieme di dati, se esiste, è l'**unico valore che ha la frequenza massima**. Se non vi è solo valore con frequenza massima, ciascuno di essi è detto **valore modale**.

Perchè scegliere la moda, invece, di media o mediana?

La moda identifica il picco della distribuzione (scelta prevalente), mentre la media può rappresentare un valore che non è mai stato osservato.

3.2 Indici di dispersione

Gli **indici di dispersione** indicano quanto i dati sono concentrati o viceversa dispersi attorno a tali valori tipici.

3.2.1 Varianza e scarto quadratico medio

È interessante misurare, quindi, il grado di dispersione dei dati rispetto, ad esempio, alla media.

Si osserva che la somma di tutte le derivazioni dalla media è sempre zero:

$$\sum_{i=1}^n (x_i - \bar{X}) \cdot f_i = 0$$

Perciò, per misurare in modo significativo la dispersione dei dati rispetto alla media, si può considerare, ad esempio, la somma dei moduli delle derivazioni, oppure la somma dei quadrati delle derivazioni.

Consideriamo di avere la seguente distribuzione: N rappresenta la numerosità della popolazione.

X	Frequenze	Frequenze relative
x_1	f_1	p_1
x_2	f_2	p_2
$\vdots$	$\vdots$	$\vdots$
x_n	f_n	p_n
Totale	N	1

Definizione: varianza

Si chiama **varianza** di X la media degli scarti al quadrato:

$$s_X^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \bar{X})^2 \cdot f_i = \sum_{i=1}^n (x_i - \bar{X})^2 \cdot p_i$$

Definizione: scarto quadratico medio

Si chiama **scarto quadratico medio** o **deviazione standard** di X la radice della varianza:

$$s_X = \sqrt{\frac{1}{N} \sum_{i=1}^n (x_i - \bar{X})^2 \cdot f_i} = \sqrt{\sum_{i=1}^n (x_i - \bar{X})^2 \cdot p_i}$$

La varianza e la deviazione standard sono grandezze non negative che si annullano solo quando gli x_i , sono tutti uguali tra loro e, quindi, uguali alla loro media.

Il calcolo della varianza può essere semplificato se si nota che, prese comunque due costanti a e b , se si considera il nuovo insieme di dati $y_i := ax_i + b$, dove $i = 1, 2, \dots, n$, allora per quanto già detto $\bar{Y} = a\bar{X} + b$ e, quindi:

$$\sum_{i=1}^n (y_i - \bar{Y})^2 = a^2 \sum_{i=1}^n (x_i - \bar{X})^2$$

Perciò, se s_y^2 e s_x^2 sono le rispettive varianze campionarie, si ha che:

$$s_y^2 = a^2 s_x^2$$

Esempio: calcolo della varianza e deviazione standard

Consideriamo la seguente distribuzione di frequenze:

Distribuzione	Frequenze
$110 < D \leq 130$	20
$130 < D \leq 150$	40
$150 < D \leq 170$	60
$170 < D \leq 210$	80
Totale	200

La media è uguale a:

$$\bar{D} = \frac{1}{200} (120 \cdot 20 + 140 \cdot 40 + 160 \cdot 60 + 190 \cdot 80) = \mathbf{164}$$

Distribuzione	$(D - \bar{D})^2$	D^2	Frequenze
$110 < D \leq 130$	$(120 - 164)^2$	120^2	20
$130 < D \leq 150$	$(140 - 164)^2$	140^2	40
$150 < D \leq 170$	$(160 - 164)^2$	160^2	60
$170 < D \leq 210$	$(190 - 164)^2$	190^2	80
Totale			200

La varianza è uguale a:

$$s_D^2 = \frac{1}{200} [(120 - 164)^2 \cdot 20 + (140 - 164)^2 \cdot 40 + (160 - 164)^2 \cdot 60 + (190 - 164)^2 \cdot 80] = \mathbf{584}$$

Lo scarto quadratico medio è uguale a:

$$s_D = \sqrt{s_D^2} = \mathbf{24.17}$$

3.3 Campioni normali

Osservando gli istogrammi dei campioni numerici forniti da esperimenti reali, si può notare che v sia una forma caratteristica che compare molto spesso e accomuna un gran numero di campioni di dati, provenienti dai contesti più disparati.

Questi grafici hanno un solo massimo, in corrispondenza della mediana, e decrescono da entrambi i lati simmetricamente, secondo una curva a campana.

Campioni di dati che rispettano questi requisiti si dice **normale**.

In realtà, pur mantenendo un aspetto simile a quello descritto, non capita mai che un istogramma reale rispetti perfettamente la simmetria e la monotonia.

Si può parlare, allora di campione appositivamente normale.

Se un campione di dati presenta un istogramma che è sensibilmente asimmetrico rispetto alla mediana, si parla di **campione swecked** (sbilanciato) a sinistra o a destra, a seconda del lato in cui ha la più lunga.

Correlazione tra variabili e regressione lineare

4.1 Correlazione tra variabili

Talvolta, per ogni individuo vengono misurati più caratteri: peso, altezza, sesso, reddito, ecc. Consideriamo, ora, il caso dei due caratteri quantitativi e supponiamo che siano sotto forma di coppie:

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

Ogni coppia fa riferimento a un individuo.

In un primo approccio grafico, si possono disegnare sul piano tutti i punti di coordinate (x_i, y_i) e vedere se essi tendono a disporsi secondo un andamento regolare.

Questo tipo di rappresentazione grafica si chiama **scatterplot** o **diagramma di dispersione**.

L'idea è quella di trovare la curva (retta, parabola ecc.), se esiste, che meglio descriva l'andamento dei dati per poi utilizzarla per "stimare" il valore di un carattere conoscendo l'altro.

Definizione: covarianza

Supponiamo di avere N osservazioni congiunte di due variabili X e Y :

$$(x_1, y_1), \dots, (x_n, y_n)$$

Si chiama **covarianza** tra X e Y la quantità:

$$s_{xy} = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y}) = \bar{XY} - \bar{X} \dots \bar{Y}$$

Si dice che le variabili X e Y sono:

- ▷ **direttamente correlate** se $s_{xy} > 0$
- ▷ **inversamente correlate** se $s_{xy} < 0$

▷ **incorrelate** se $s_{xy} = 0$

Definizione: coefficiente di correlazione

Si chiama **coefficiente di correlazione** di X e Y la quantità:

$$\rho_{xy} = \frac{s_{xy}}{s_x s_y}$$

ovvero, la covarianza divisa per il prodotto delle deviazioni standard.

N.B. coefficiente di correlazione è definito solo se $s_x \neq 0$ e $s_y \neq 0$ (se entrambi non sono costanti).

Proprietà del coefficiente di correlazione campionaria

Di seguito diamo alcune delle proprietà del coefficiente di correlazione campionaria ρ_{xy} :

- sempre $-1 \leq \rho_{xy} \leq 1$
- se per opportune costanti a e b ($b > 0$), sussiste la relazione lineare:

$$y_i = a + bx, \quad \forall i = 1, 2, \dots, n$$

allora $\rho_{xy} = 1$.

- se per opportune costanti a e b ($b < 0$), sussiste la relazione lineare:

$$y_i = a + bx, \quad \forall i = 1, 2, \dots, n$$

allora $\rho_{xy} = -1$.

- se ρ_{xy} è il coefficiente di correlazione del campione (x_i, y_i) , $i = 1, \dots, n$, allora lo è anche per il campione:

$$(a + bx_i, c + dy_i), \quad \forall i = 1, 2, \dots, n$$

purchè le costanti d e d abbiano lo stesso segno.

4.2 Regressione lineare

... verrà trattato più avanti

Calcolo combinatorio

5.1 Permutazione

Consideriamo tre palline colorate.



Figura 5.1: palline colorate

Disegniamo ora, tutte le possibile sequenze ordinate che si possono ottenere con le tre palline.




Figura 5.2: permutazioni di tre palline

Definizione: permutazione semplice

Le **permutazioni semplici** sono tutte le possibili sequenze ordinate di n oggetti.

$$p_n = n \cdot (n - 1) \cdot (n - 2) \cdot \dots \cdot 1 = n!$$

Esercizio 1

In quanti modi si possono disporre 10 persone in 10 sedie?

$$\boxed{10} \cdot \boxed{9} \cdot \boxed{8} \cdot \boxed{7} \cdot \boxed{6} \cdot \boxed{5} \cdot \boxed{4} \cdot \boxed{3} \cdot \boxed{2} \cdot \boxed{1} = 10!$$

Esercizio 2

Calcolare il numero degli anagrammi della parola "CUORE".

$$p_5 = \boxed{5} \cdot \boxed{4} \cdot \boxed{3} \cdot \boxed{2} \cdot \boxed{1} = 5!$$

Esercizio 3

Calcolare il numero degli anagrammi della parola "PICCHE".

In questo caso il numero totale di permutazioni non può essere calcolato come la semplice sequenza ordinata scambiando le varie lettere della parola picche, perchè la c è presente due volte (picche = picche).

Il numero totale di permutazioni (in caso di ripetizioni di alcuni oggetti):

$$p_n = \frac{\text{tot. permutazioni tutti n oggetti}}{\text{tot. permutazioni oggetti ripetuti}} = \frac{6!}{2!} = \frac{6 \cdot 5 \cdot 4 \cdot 3 \cdot 2!}{2!} = 90$$

5.2 Disposizione

Consideriamo una gara di corsa con 9 partecipanti.



Figura 5.3: gara di corsa

Quanti podi (3 persone) si possono creare da un gruppo di 9 persone?




Figura 5.4: disposizione

Per il primo posto abbiamo 9 possibilità, per il secondo posto 8 possibilità e per il terzo posto 7 possibilità.

Definizione: disposizione semplice

Una **disposizione semplice** è un sotto-insieme di k elementi diversi tra loro selezionati da un insieme di partenza avente n elementi.

$$D_{n,k} = n \cdot (n-1) \cdot (n-2) \dots (n-k+1) \cdot \frac{(n-k) \cdot (n-k-1) \dots 2 \cdot 1}{(n-k) \cdot (n-k-1) \dots 2 \cdot 1}$$

$$= \frac{n!}{(n-k)!}$$

N.B. Nelle disposizioni è importante l'ordine!

Osservazione

Due disposizioni sono diverse se cambia **almeno** un elemento, oppure se gli stessi elementi compaiono in ordine differente.

Esercizio 1

Quanti numeri di 3 cifre distinte si possono fare utilizzando solo cifre dispari?

$cifre_{dispari} = 1, 3, 5, 7, 9$

$$\boxed{5} \cdot \boxed{4} \cdot \boxed{3}$$

$$D_{5,3} = \frac{5!}{2!} = \frac{5 \cdot 4 \cdot 3 \cdot \cancel{2!}}{\cancel{2!}} = 60$$

Esercizio 2

Calcolare la soluzione di:

$$3D_{x,4} = D_{x,5}$$

$$D_{x,4} = \frac{x!}{(x-4)!} = \frac{x \cdot (x-1) \cdot (x-2) \cdot (x-3) \cdot \cancel{(x-4)!}}{\cancel{(x-4)!}}$$

$$D_{x,5} = \frac{x!}{(x-5)!} = \frac{x \cdot (x-1) \cdot (x-2) \cdot (x-3) \cdot (x-4) \cdot \cancel{(x-5)!}}{\cancel{(x-5)!}}$$

Osservazione

$$x \geq 5$$

$$3x(x-1)(x-2)(x-3) = x(x-1)(x-2)(x-3)(x-4)$$

$$3 = x-4$$

$$x = 7$$

5.3 Combinazione

Definizione: combinazione semplice

Una **combinazione semplice** è un sotto-insieme di k elementi distinti estratti da un insieme di partenza di n elementi.

$$C_{n,k} = \binom{n}{k} = \frac{n!}{k! \cdot (n-k)!}$$

Probabilità

Definizione: probabilità classica

La **probabilità classica** si calcola come:

$$P_{\text{classica}} = \frac{\text{n° casi favorevoli}}{\text{n° casi possibili}}$$

Esempio: lancio del dado

Qual'è la probabilità di ottenere 4 lanciando un dado da 6 faccie?

$$P = \frac{1}{6}$$

Esempio: lancio della moneta

Qual'è la probabilità di ottenere testa lanciando una moneta

$$P = \frac{1}{2}$$

La definizione di probabilità classica, però, vale solo quando gli eventi sono **equiprobabili** e, inoltre, presuppone un numero finito di casi possibili.

6.1 Probabilità non condizionata

Definizione: eventi (in)compatibili

Due eventi si dicono **compatibili** se possono accadere contemporaneamente.

Due eventi si dicono **incompatibili** se **non** possono accadere contemporaneamente.

Teorema della probabilità totale

Siano A e B due eventi diversi tra loro:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- ▷ $P(A \cup B)$: probabilità che si verifichi A o B (almeno uno dei due eventi)
- ▷ $P(A \cap B)$: probabilità che si verifichi sia A che B (contemporaneamente)

Nel caso in cui i due eventi sono incompatibili, allora $P(A \cap B) = 0$.

Esempio: lancio del dado

Qual'è la probabilità che lanciando un dado esca come risultato 3 oppure 4?

⇒ gli eventi A (esce 3) e B (esce 4) sono due eventi incompatibili, perchè non può uscire 3 e contemporaneamente 4.

Di conseguenza:

$$\begin{aligned} P &= P(A) + P(B) - \cancel{P(A \cap B)} \\ &= \frac{1}{6} + \frac{1}{6} - 0 \\ &= \frac{1}{3} \end{aligned}$$

Esempio: lancio del dado

Qual'è la probabilità che lanciando un dado esca un numero pari o un multiplo di 3?

⇒ gli eventi A (esce un numero pari) e B (esce un numero multiplo di 3) sono due eventi compatibili, perchè:

- ▷ numeri pari: $\{2, 4, 6\}$
- ▷ multipli di 3: $\{3, 6\}$

Di conseguenza:

$$\begin{aligned} P &= P(A) + P(B) - P(A \cap B) \\ &= \frac{3}{6} + \frac{2}{6} - \frac{1}{6} \\ &= \frac{2}{3} \end{aligned}$$

Il teorema della probabilità totale si può generalizzare anche quando si considerano 3 o più eventi.


6.2 Probabilità condizionata

Definizione: eventi (in)dependenti

Due eventi si dicono **indipendenti** se il fatto che si verifichi (o meno) il primo **non**, altera la probabilità che si verifichi il secondo.

Due eventi si dicono **dipendenti** se il fatto che si verifichi (o meno) il primo, altera la probabilità che si verifichi il secondo.

Qual'è la probabilità che lanciando contemporaneamente un dado e una moneta si ottengono un 4 e una testa?



I due eventi sono indipendenti:

$$P = \frac{1}{6} \cdot \frac{1}{2} = \frac{1}{12}$$

Eventi indipendenti

Se A e B sono due eventi indipendenti:

$$P(A \cap B) = P(A) \cdot P(B)$$

In una classe ci sono 20 alunni (12 femmine e 8 maschi): se la prof ne sceglie 2 random, qual'è la probabilità che scelga due ragazze?

I due eventi sono dipendenti:

$$P = \frac{\binom{12}{2}}{\binom{20}{2}} = \frac{\frac{12!}{2! \cdot 10!}}{\frac{20!}{2! \cdot 18!}} = \frac{12 \cdot 11}{20 \cdot 19}$$

⇒ $\frac{12}{20}$: probabilità di scegliere una ragazza

⇒ $\frac{11}{19}$: probabilità di scegliere una ragazza, sapendo che ne ho già scelta una prima

Eventi dipendenti

Se A e B sono due eventi dipendenti:

$$P(A \cap B) = P(A) \cdot P(B | A)$$

Variabili aleatorie

Definizione: Variabile aleatoria

Dato uno spazio di probabilità $(\Omega, \mathcal{F}, \mathbb{P})$, una **variabile aleatoria** su Ω è una funzione che ad ogni $\omega \in \Omega$ associa un numero reale

$$X : \Omega \rightarrow \mathbb{R}$$

tale che, per ogni $a \leq b \in \mathbb{R}$, sia possibile calcolare la probabilità dell'insieme

$$\{\omega \in \Omega : a < X(\omega) \leq b\}$$

che, quindi, deve essere un evento di $\mathcal{F}$.

Le variabili aleatorie si distinguono in due categorie:

- ▷ **variabili aleatorie discrete**
 - ◊ finite
 - ◊ numerabili
- ▷ **variabili aleatorie continue**

Definizione: Variabili aleatorie discrete

Una **variabile aleatoria** X si dice **discreta** se l'insieme E è discreto.

In particolare:

- **finita**: se l'insieme E è un insieme finito
- **numerabile**: se l'insieme E è un insieme numerabile

Definizione: Variabile aleatoria continua

Una **variabile aleatoria** si dice **continua** se l'insieme E è un insieme continuo.

7.1 Variabili aleatorie finite

Esempio: lancio del dado

Consideriamo il lancio di un dado. Sia X la variabile che vale 0 se esce un numero pari e 1 se esce un numero dispari.

Abbiamo così:

$$\triangleright \Omega = \{1, 2, 3, 4, 5, 6\}$$

$$\triangleright E = \{0, 1\} \text{ (insieme dei valori assunti da } X\text{)}$$

Si ha:

$$X(1) = X(3) = X(5) = 1$$

$$X(2) = X(4) = X(6) = 0$$

L'insieme dei valori assunti da X e le probabilità con cui vengono assunti si chiama **legge o distribuzione di X** .

Definizione: Funzione di ripartizione

La **funzione di ripartizione** di una variabile aleatoria discreta X è definita da:

$$F_X(x) = \mathbb{P}(X \leq x) = \sum_{t \leq x} p_X(t)$$

La variabile aleatoria essendo una funzione di esperimenti, essa assume i suoi valori con una certa probabilità.

Esempio: lancio del dado

Consideriamo l'esempio fatto in precedenza sul lancio del dado.

Cosa vuol dire che $X = 0$?

Significa che il lancio ha dato un risultato pari.

$$\{X = 0\} \equiv \{2, 4, 6\}$$

Ciò significa che:

$$\mathbb{P}(X = 0) = \mathbb{P}(\{2, 4, 6\}) = \frac{3}{6} = \frac{1}{2}$$

Cosa vuol dire che $X = 1$?

Significa che il lancio ha dato un risultato dispari.

$$\{X = 1\} \equiv \{1, 3, 5\}$$

Ciò significa che:

$$\mathbb{P}(X = 1) = \mathbb{P}(\{1, 3, 5\}) = \frac{3}{6} = \frac{1}{2}$$

Facciamo una tabella riassuntiva:

Valore x_i	Sottoinsieme di Ω	$P(X = x_i)$
0	$\{2, 4, 6\}$	$\frac{1}{2}$
1	$\{1, 3, 5\}$	$\frac{1}{2}$

Laboratorio

8.1 Introduzione ad R

R è stato avviato dai professori Ross Ihaka e Robert Gentleman come linguaggio di programmazione per insegnare statistica introduttiva all'Università di Auckland nel 1993.

- Il linguaggio ha preso forte ispirazione dal linguaggio di programmazione S.
- Il Comprehensive R Archive Network (CRAN) è stato fondato nel 1997 da Kurt Hornik e Fritz Leisch per ospitare il codice sorgente di R, i file eseguibili, la documentazione e i pacchetti creati dagli utenti.
- In origine, CRAN aveva tre mirror e 12 pacchetti contribuiti. A dicembre 2022 conta 103 mirror e 18.976 pacchetti contribuiti

8.1.1 Pacchetti importanti

ggplot2: per la visualizzazione dei dati

dplyr: per la manipolazione dei dati, inclusi filtraggio, raggruppamento e sintesi dei dati

tidyr: per pulire e ristrutturare i dati

caret: per il machine learning

lubridate: per lavorare con date e orari

stringr: per lavorare con le stringhe, incluse funzioni per il pattern matching, la manipolazione delle stringhe e le espressioni regolari

reshape2: per trasformare i dati tra formati "wide" e "long"

data.table: per la manipolazione e aggregazione dei dati, particolarmente utile per lavorare con dataset di grandi dimensioni

Per installare e utilizzare un pacchetto

```
1 install.packages("package_name") # install the package
2 library("package_name") # load the package
```

8.2 Primi comandi

Puoi eseguire comandi nella console di R, ad esempio per calcolare un'espressione matematica:

```
1 > 1+1  
2 [1] 2
```

Oppure scrivi la stessa espressione in un file script .R e poi premi <Ctrl> + Enter per inviare la riga selezionata alla console.

Puoi anche dichiarare variabili usando gli operatori <- o =

```
1 > A <- 1+1  
2 > A  
3 [1] 2
```

8.2.1 Cronologia dei comandi

In R, puoi vedere i comandi precedenti usando la freccia su nella console. Ogni pressione mostra il comando precedente, che puoi modificare o eseguire. In alternativa, usa la funzione `history()` nella console o il pannello History per accedere alla cronologia della sessione corrente.

8.2.2 Ottenere aiuto (help)

Per accedere alla documentazione di una funzione o di un pacchetto, digita nella console: `?nome_funzione` o `?nome_pacchetto` e premi Enter

```
1 > #Get help for the mean() function  
2 > ?mean
```

Nota

Usando la sintassi `??"search term"` ottieni una lista di tutte le pagine di aiuto che contengono il termine

In alternativa è possibile usare: `help(function_name)` or `help(package_name)`

```
1 > # This time get help using help() function  
2 > help(mean)
```

In uno script.R premendo <Ctrl> + F1 con il nome di una funzione selezionato si apre la relativa documentazione.

Il pannello Help mostra tutte le informazioni disponibili. Se non basta, esistono molte risorse online

8.3 Variabili semplici

Quando vuoi memorizzare il risultato di un calcolo per riutilizzarlo o dargli un nome sensato per rendere il codice più leggibile, definisci una variabile

8.3.1 Assegnazione, Sovrascrittura, Rimozione

Assegnazione

```
1 > students <- 100
```

Creata variabile students di tipo numerico. Il valore 100 viene memorizzato

Sovrascrittura

```
1 > students <- 102
2 > students
3 [1] 102
```

Si può controllare il contenuto digitando il nome della variabile nella console o guardando il pannello environment

Rimozione variabili

```
1 > remove(students)      #Removes a single variabile
2 > remove(list = ls())   # Removes all the variables listed by the
    ls() function
```

8.4 Vettori

Un vettore in R è una lista di elementi

Creazione

```
1 > v1 <- c(2, 5, 1)
```

Creazione di un vettore numerico contenente 3 elementi

Accedere agli elementi di un vettore

```
1 > v1[1]      #La parentesi quadra indica l'indice di interesse
2 [1] 2
```

L'indicizzazione parte da 1

Creazione vettore come unione di più vettori

```
1 > r <- c(2, 4, 10)
2 > w <- c(9, -6, 4)
3 > u <- c(r, w)
4 [1] 2 4 10 9 -6 4
```

Operatore due punti

```

1 > x1 <- 1:10
2 > x1
3 [1] 1 2 3 4 5 6 7 8 9 10

```

L'operatore due punti genera un vettore di elementi regolarmente distribuiti

Funzione seq() Per creare sequenze più specifiche si usa la funzione **seq()**

```

1 > x2 <- seq(from = 0, to = 0.5, by = 0.1)
2 > x2
3 [1] 0.0 0.1 0.2 0.3 0.4 0.5

```

Funzioni correlate

- **seq_along()**: crea un vettore con tanti elementi quanti quelli del vettore passato tra parentesi
- **seq_len()**: crea un vettore con tanti elementi quanti indicati da un argomento intero

8.4.1 Ripetizioni di vettori

```

1 > r1 <- rep(c(1,2,3), times = 3)
2 > r1
3 [1] 1 2 3 1 2 3 1 2 3

```

Esempio: il vettore 1, 2, 3 ripetuto 3 volte

Per ripetere **ogni elemento** un numero specifico di volte, usa gli argomenti di **rep()**

```

1 > r2 <- rep(c(1,2,3), each = 3)
2 > r3 <- rep(c(1,2,3), times = c(1,2,3))
3 > r2
4 [1] 1 1 1 2 2 2 3 3 3
5 > r3
6 [1] 1 2 2 3 3 3

```

8.4.2 Funzioni utili per i vettori

length(): Restituisco la lunghezza del vettore

max(), **min()**: Calcola il valore massimo e minimo

sum(): Somma tutti gli elementi

mean(): Calcola la media

cumsum(): Calcola la somma cumulativa di ogni elemento

8.5 Matrici

Come creare una matrice:

- concatenando vettori come colonne (funzione **cbind**)

- concatenando vettori come righe (funzione **rbind**)
- usando la funzione **matrix()**, specificando numero di righe e colonne

```
1 > mat1 <- cbind(c(1,2,3), c(4,5,6))
2 > mat2 <- rbind(c(1,2,3), c(4,5,6))
3 > mat3 <- matrix(data = c(1,2,3,4,5,6), nrow = 3, ncol = 2)
```

```
> mat1
  [,1] [,2]
[1,]  1   4
[2,]  2   5
[3,]  3   6
```

```
> mat2
  [,1] [,2] [,3]
[1,]  1   2   3
[2,]  4   5   6
```

```
> mat3
  [,1] [,2]
[1,]  1   4
[2,]  2   5
[3,]  3   6
```

Accedere agli elementi

Per accedere agli elementi della matrice servono due indici, uno per le righe e uno per le colonne.

```
1 > mat1 <- cbind(c(1,2,3), c(4,5,6))
2 > mat2[2,2] #element in second row, second column
3 [1] 5
```

Per ottenere tutti gli elementi di una riga o colonna bisogna lasciare vuoto l'indice opposto

```
1 > mat1[,2] #elementi della seconda colonna
2 [1] 4 5 6
3 > mat2[2,] #elementi della seconda riga
4 [1] 2 5
```

Selezionare sottoinsieme di righe e colonne

```
1 > mat1 <- cbind(c(1,2,3), c(4,5,6))
2 > mat1[2:3, 1:2] #seconda e terza riga, entrambe le colonne
3      [,1] [,2]
4 [1,]  2   5
5 [2,]  3   6
```

Lo stesso approccio può essere utilizzato per i vettori. Gli indici degli elementi da rimuovere sono preceduti da un simbolo meno.

8.5.1 Matrici speciali

Esistono matrici particolari come matrici nulle, identità o diagonali

```
1 > mat_zero <- matrix(0, 3, 3) #Matrice 3x3 di zeri
2 > mat_ones <- matrix(1,3, 3) #Matrice 3x3 di uno
3 > mat_id <- diag(3) #Matrice identità 3x3
```

```

> mat_zero
      [,1] [,2] [,3]
[1,]    0    0    0
[2,]    0    0    0
[3,]    0    0    0

> mat_ones
      [,1] [,2] [,3]
[1,]    1    1    1
[2,]    1    1    1
[3,]    1    1    1

> mat_id
      [,1] [,2] [,3]
[1,]    1    0    0
[2,]    0    1    0
[3,]    0    0    1

```

8.5.2 Operazioni con vettori e matrici

Le operazioni aritmetiche come somma, sottrazione, moltiplicazione e divisione vengono eseguite elemento per elemento

```

1 > A <- matrix(data = 1:9, nrow = 3)
2 > B <- A + 1

```

```

> A
      [,1] [,2] [,3]
[1,]    1    4    7
[2,]    2    5    8
[3,]    3    6    9

```

(a) matrice A

```

> B
      [,1] [,2] [,3]
[1,]    2    5    8
[2,]    3    6    9
[3,]    4    7   10

```

(b) matrice B (elementi A+1)

Altre operazioni elemento per elemento sono l'elevamento a potenza e la radice quadrata

```

1 > C <- A^2
2 > D <- sqrt(A)

```

```

> C
      [,1] [,2] [,3]
[1,]    1   16   49
[2,]    4   25   64
[3,]    9   36   81

```

```

> D
      [,1] [,2] [,3]
[1,] 1.000000 2.000000 2.645751
[2,] 1.414214 2.236068 2.828427
[3,] 1.732051 2.449490 3.000000

```

Per ottenere statistiche riepilogative è possibile utilizzare le funzioni `sum()`, `mean()`, `max()`

```

1 > sum(A)      #45      > min(A)    #1
2 > mean(A)     #5       > max(A)    #9

```

Le operazioni elemento per elemento possono essere eseguite anche tra matrici (purchè siano conformi tra loro)

```
1 > A <- matrix(data = 1:9, nrow = 3) #3x3
2 > E <- matrix(data = 1:4, nrow = 2) #2x2
3 > A + E
4 Error in A + E : non-conformable arrays
```

Le operazioni tra matrici seguono le regole dell'algebra lineare (cioè la dimensione e la forma necessarie degli input in relazione tra loro dipendono dall'operazione).

L'operatore `%*%` esegue la moltiplicazione tra matrici, mentre la funzione `t()` calcola la trasposta

```
1 > v1 <- c(1,2,3)
2 > v2 <- c(4,5,6)
3 > v1 * v2
4 [1] 4 10 18
5 #Still element-wise
```

```
1 > t(v1) %*% v2
2 [1] 32
```

```
1 > v1 %*% t(v2)
2      [,1] [,2] [,3]
3 [1,]    4    5    6
4 [2,]    8   10   12
5 [3,]   12   15   18
```

```
1 > v1 %*% t(v2)
2      [,1] [,2] [,3]
3 [1,]    4    5    6
4 [2,]    8   10   12
5 [3,]   12   15   18
```

8.5.3 Funzioni utili per le matrici

det(): Restituisce il determinante di una matrice

qr(): Calcola la decomposizione QR

solve() Inversa di una matrice

nrow(), ncol(): Restituisce il numero di righe e di colonne

rowSums(), colSums(): Restituisce la somma di tutti gli elementi per riga o per colonna

rowMeans(), colMeans(): Restituisce la media di ogni riga o di ogni colonna

dim(): Restituisce il numeri di righe e colonne

8.6 Caratteri

Le variabili di tipo character servono per memorizzare testo.

```
1 > month <- "March" #testo contenuto tra "" o ''
```

Viene creata una variabile chiamata **month** che contiene la stringa "March"

8.6.1 Funzioni utili

nchar(): Restituisce la lunghezza di una stringa

paste(), paste0() Unisce (concatena) due o più stringhe con o senza spazio

toupper(): Converte il testo in maiuscolo o minuscolo

Come per i vettori numerici, è possibile creare vettori di caratteri

```
1 > months <- c("january", "february", "march")
```

8.7 Liste, Array e Data Frame

Le liste, gli array e i data frame sono tra i tipi di dati più flessibili in R.

8.7.1 Liste

Una lista è una collezione di dati che possono essere:

- dello stesso tipo
- di tipi diversi

Creazione

Per creare una lista si usa la funzione `list()`

```
1 > l1 <- list("Everest", "Nepal", 8848, TRUE)
2 > l2 <- list(81, 82, 90, 56)
```

`l1` contiene valori character, numerici e booleani, `l2` contiene solo valori numerici

Come accedere

```
1 > l1[1]
2 [[1]]
3 [1] "Everest"
```

Accedere agli elementi di una lista è molto simile ai vettori

8.7.2 Array

Un array è una struttura di dati che può memorizzare dati dello stesso tipo in più di due dimensioni.

- **Vettori** → una dimensione
- **Matrici** → due dimensioni
- **Array** → più dimensioni

```

1 > a1 <- array(c(1:12), dim = c(2,3,2))
2 > a1
3 , , 1
4      [,1] [,2] [,3]
5 [1,]    1    3    5
6 [2,]    2    4    6
7
8
9 , , 2
10     [,1] [,2] [,3]
11 [1,]    7    9   11
12 [2,]    8   10   12

```

Accesso agli elementi di un array

In un array R, `a1[i, j, k]` indica l'elemento alla *i*-esima posizione della prima dimensione (righe), *j*-esima della seconda dimensione (colonne) e *k*-esima della terza dimensione (livello / profondità)

8.7.3 Data-Frame

Un data frame è una **struttura di dati bidimensionale** che permette di memorizzare dati in forma tabellare. I data frame hanno righe e colonne, e ogni colonna può essere un vettore diverso. I vettori possono anche avere tipi di dati differenti.

```

1 > df1 <- data.frame(
2   mount = c("Everest", "K2", "Fuji"),
3   height = c(8848, 8611, 3776),
4   todo = c(TRUE, TRUE, FALSE))
5 > df1
6      mount height  todo
7 1 Everest   8848  TRUE
8 2      K2   8611  TRUE
9 3     Fuji   3776 FALSE
10 > df1$mount #Accedere ad una colonna $
11 [1] "Everest" "K2" "Fuji"

```

Concatenazione

Si usano le funzioni `cbind()` e `rbind()` per unire due data frame orizzontalmente o verticalmente

Accesso

`df1$mount`, `df1[, "mount"]` e `df1[, 1]` sono modi equivalenti per accedere alla prima colonna del data frame

8.8 Fattori

Un **factor** è una struttura di dati utilizzata per lavorare con **dati categorizzabili**. La funzione `factor()` può essere usata per creare un factor. Una volta creato, un factor può contenere solo un insieme di valori predefiniti chiamati livelli(levels)-l e categorie uniche

```

1 > f1 <- marital_status <- factor(c("married", "single", "single",
2   "divorced", "married"))
3 > f1
4 [1] married single single divorced married
5 Levels: divorced married single
6 > levels(f1)
7 [1] "divorced" "married" "single"
8 > f1[1] <- "hey"
9 Warning message:
10 In '[<-.factor'('*tmp*', 1, value = "hey") :
   invalid factor level, NA generated]
```

8.8.1 Strutture if, else

Costrutto if-else

Effettua un blocco di codice solo se la condizione è vera

```

1 if (condizione){
2   # istruzione
3 } else if (condizione) {
4   # istruzione
5 }
```

Costrutto ifelse

Controlla una condizione per ogni elemento di un vettore e restituisce valori diversi secondo il risultato.

```

1 ifelse(condizione, yes = ..., no = ...)
2
3 > #Esempio
4 > voti <- c(6,9,10)
5 > ifelse(voti > 8, yes = "Ottimo", no = "Sufficiente")
6 [1] "Sufficiente" "Ottimo" "Ottimo"
```

8.8.2 Struttura for, while

Ripete un blocco di codice per ogni elemento di una sequenza o vettore


```

1 for(variabile in vettore){
2   #istruzione ripetute per ogni elemento del vettore
3 }

```

Cotrolla una condizione per ogni elemento di un vettore e restituisce valori diversi secondo il risultato.

```

1 while(condizione){
2   # istruzione ripetute finche la condizione e' TRUE
3 }

```

8.9 Rappresentazione Grafica


Per creare un grafico si può usare la funzione `plot()` integrata in R.

Esempio di grafico a dispersione(scatterplot)

```

1 x <- c(1,2,3,4,5)
2 y <- c(2,4,6,8,10)
3
4 # Crea un scatterplot
5 plot(x,y)

```



Tipologie di grafici

BarPlot: I grafici a barre sono usati per visualizzare dati categorici. Ogni varra rappresenta una categoria e l'altezza della barra rappresenta la frequenza o proporzione di quella categoria.

Grafici a linee: Usati per mostrare tendenze o variazioni nel tempo

Istogrammi(hist()): usati per mostrare la distribuzione di una variabile continua. L'asse X rappresenta l'intervallo di valori e l'asse Y rappresenta la frequenza o proporzione dei valori di ciascun intervallo.

BoxPlot: Usati per visualizzare la distribuzione di una variabile continua.


Grafici a dispersione: Usati per mostrare la relazione tra due variabili continue, dove ogni punto dati è rappresentato da un punto su un grafico bidimensionale

Grafici di densità: Usati per visualizzare la distribuzione continua tramite una curva liscia.

8.9.1 Grafico a Barre

Usando il comando `plot(..., type = "l")`:


```
1 ages = 20:29
2 students = c
   (2,1,5,3,4,2,0,2,1,0)
3 barplot(students,
4 xlab = "Age of students",
5 ylab = "Number of students",
6 names.arg = ages)
```



8.9.2 Line Plot

Usando il comando `plot(..., type = "l")`:

```
1 > #Genera 100 valori casuali tra 10
   e 20
2
3 daily_income <- runif(100, min =
4 10, max = 20)
5
6 plot(daily_income,
7 type = "l",
8 xlab = "Day",
9 ylab = "Daily Income",
   main = "Daily incomes over 100
   days")
```




8.9.3 Istogramma

Usando il comando `hist()`:

```

1 > #Genera 100 valori casuali tra 40
  e 80
2
3 weights <- runif(100, min = 40, max
  = 80)
4 > #In R, per vedere i primi
  elementi di un vettore, puoi
  usare la funzione head()
5
6 head(weights)
7
8 hist(weights, breaks = c
  (40,50,60,70,80))

```




8.9.4 BoxPlot

Usando il comando `boxplot()`:

```

1 > #Genera 50 valori casuali tra 40
  e 80
2 > #Genera 50 valori casuali tra 45
  e 70
3
4 > height <- c(runif(50, min = 40,
  max = 80),
  runif(50, min = 45, max = 70))
5
6 > group <- rep(c("A", "B"), each =
  50)
7
8 > boxplot(height ~ group, main = "
  Heights by group boxplots")

```




8.9.5 Mostrare più grafici contemporaneamente

Usando il comando `par(mfrow = C(nrighe, ncolonne))` è possibile impostare il layout per più grafici

```

1 > #Definire dei dati
2 > x = 1:6
3 > y = c(33,11,5,9,22,30)
4 > #Impostare il layout, 2 righe e 2
   colonne
5 > par(mfrow = c(2,2))
6 > #Posizione [1,1]
7 > barplot(y, main = "Barplot",
   names.arg = x)
8 > #Posizione [1,2]
9
10 > barplot(y, main = "Horizontal
   Barplot", names.arg = x, horiz =
   TRUE)
11
12 > #Posizione [2,1]
13 > plot(x, y, type = "l", main = "
   Line plot")# Posizione [2, 2]
14
15 > plot(x, y, main = "Scatter plot",
   col = "red")

```



8.9.6 Salvare ed esportare grafici

Per salvare un grafico, è possibile usare le funzioni `pdf()`, `jpeg()`, `svg()` per creare un nuovo dispositivo grafico e poi usare la funzione `plot()` per creare il grafico. Una volta creato il grafico, puoi usare la funzione `dev.off()` per chiudere il dispositivo grafico e salvare il grafico in un file.

```

1 > #Crea un nuovo dispositivo grafico pdf
2 > pdf("./plots/myplot.pdf")
3 > #Qui bisogna indicare la directory dove salvare il file
4 > #Crea un grafico
5   x <- 1:10
6   y <- y^2
7   plot(x,y)
8 > #Chiudi il dispositivo grafico e salva il grafico nel file
9   dev.off()

```

8.10 Salvare e caricare

8.10.1 variabili

Le variabili in R possono essere salvate utilizzando due formati principali:

- **.RData** è usato per salvare uno o più oggetti in un unico file.
 - Salvare: `save()`
 - Caricare: `load()`
- **.RDS** è un formato usato per salvare un singolo oggetto R in un file

- Salvare: `saveRDS()`
- Caricare: `readRDS`

8.10.2 Dati Tabulari

Spesso i dati da importare o esportare sono organizzati in formato tabellare. Ci sono diverse opzioni:

- `read.csv()/write.csv()` e `read.table() / write.table()`
- `read_excel() / write_excel()` dal pacchetto `readxl`: importare o esportare dati da/verso file Excel
- `readr::read_delim()/write_delim()` e `readr::read_csv()/write_csv()`: utilizzate per importare o esportare da file di testo delimitati inclusi **CSV, TSV** ...

8.11 File.R - script e funzioni

Gli script e le funzioni sono due componenti che permettono di scrivere e riutilizzare codice:

- **Script**: è un file di testo contenente una sequenza di comandi R che si desidera seguire. Oer eseguirli si utilizza la funzione `source()`
- **Funzione**: è un blocco di codice che svolge un compito specifico e può essere richiamato da altre parti del codice. Le funzioni in R si definiscono usando `function()`

```
1 my_sum <- function(x,y){
2     z <- x + y
3     return(z)
4 }
5 #Esempio di funzione semplice
```

Le variabili create all'interno di una funzione sono locali alla funzione (esistono solo mentre viene eseguita)

```
1 my_sum(2,3) #Restituisce 5
```

8.11.1 Variabili locali e gloabali

Una variabile globale è una variabile definita al di fuori di qualsiasi funzione o blocco di codice e può essere accessibile da qualsiasi parte del programma.

```
1 x <- 10
2 my_function <- function(){
3     y <- x+1
4     return(y)
5 }
6 my_function() #Restituisce 11
```

Nota

Se si definisce una variabile con lo stesso nome all'interno di una funzione come una variabile globale, la variabile globale avrà la precedenza e quella globale sarà mascherata all'interno della funzione

8.12 Statistica Descrittiva

La statistica descrittiva è un settore della statistica che riguarda la raccolta, l'organizzazione, la sintesi e la presentazione dei dati. Fornisce un modo per descrivere e riassumere le caratteristiche di un insieme di dati, come la tendenza centrale, la dispersione, la forma e la distribuzione.

Le statistiche descrittive possono essere utilizzate per ottenere informazioni sui dati. Ad esempio, possiamo usarle per determinare l'età media di un gruppo di persone, la variabilità delle loro età e come queste sono distribuite all'interno del gruppo.

Quando un dataset contiene più di una variabile, a seconda del loro tipo (ad esempio discreta, continua, categorica...), le statistiche descrittive possono essere utilizzate per studiare le associazioni tra queste variabili (ad esempio covarianza e correlazione).

La visualizzazione aiuta a rendere più evidenti i pattern e le tendenze nei dati e può fornire una comprensione più intuitiva rispetto a una semplice tabella di numeri. Alcuni tipi comuni di visualizzazione includono grafici a dispersione, grafici a barre, grafici a linee e istogrammi.

8.12.1 Funzioni comuni

- **mean()**: Media calcola il valore medio di un dataset
- **median()**: Mediana calcola il valore centrale di un dataset
- **range()**: Calcola l'intervallo tra il valore minimo e il massimo
- **IQR()**: Intervallo interquartile: misura la dispersione calcolando la differenza tra il terzo e il primo quartile
- **var()**: Varianza: misura la dispersione calcolando la deviazione quadratica media dalla media
- **sd()**: Deviazione standard: misura la dispersione come radice quadrata della varianza
- **skewness()**: Misura il grado di asimmetria di un dataset (richiede il pacchetto "e1071")
- **kurtosis()**: Misura il grado di curtosi (appiattimento/picco) di un dataset (richiede il pacchetto "e1071")
- **cov()**: Misura il grado di associazione lineare tra due variabili in un dataset
- **cor()**: Coefficiente di correlazione: misura il grado di associazione lineare tra due variabili, con valori da -1 a 1 (è una covarianza standardizzata)

Altre funzioni utili

- **summary()**: Fornisce un sommario del dataset, includendo valori minimo e massimo, quartili, media e mediana per ciascuna variabile

```
1 summary(penguins)
2 summary(penguins$bill_length_mm)
```

- **table()**: Crea una tabella di contingenza per variabili categoriche, mostrando la frequenza di ogni combinazione

```
1 tab=table(penguins$species, penguins$island)
```

- **prop.table()**: Crea una tabella di contingenza mostrando la proporzione di ogni combinazione di categorie

```
1 prop.table(tab)
```

- **quantile()**: Calcola il valore di uno specifico quantile (es. 90° percentile)

```
1 quantile(penguins$bill_length_mm, 0.25, na.rm=TRUE)
```

8.12.2 Dataset PalmerPenguins

Il dataset palmerpenguins contiene misure dimensionali di 3 specie di pinguini osservati su tre isole nell'arcipelago di Palmer, in Antartide

I dati sono contenuti nel pacchetto **palmerpenguins** Come ottenerlo:

```
1 install.packages("palmerpenguins")
2 library("palmerpenguins")
3 data(package="palmerpenguins")
4 data("penguins")
```

Il pacchetto contiene due dataset: **penguins** e **penguins_raw**. Useremo **penguins**. Per ispezionare i dati, basta digitare il nome del dataset, usare la funzione `head()` (per vedere le prime righe del dataset), la funzione `str()` (per ottenere informazioni di base su ogni colonna del dataset), oppure cliccare sul nome del dataset nell'ambiente di lavoro.

```
1 > penguins > str(penguins)
2
3 > head(penguins) > View(penguins)
```

Output funzione `str()`

```
tibble [344 × 8] (S3: tbl_df/tbl/data.frame)
 $ species      : Factor w/ 3 levels "Adelie","Chinstrap",...: 1 1 1 1 1 1 1 1 1 1 ...
 $ island       : Factor w/ 3 levels "Biscoe","Dream",...: 3 3 3 3 3 3 3 3 3 3 ...
 $ bill_length_mm : num [1:344] 39.1 39.5 40.3 NA 36.7 39.3 38.9 39.2 34.1 42 ...
 $ bill_depth_mm : num [1:344] 18.7 17.4 18 NA 19.3 20.6 17.8 19.6 18.1 20.2 ...
 $ flipper_length_mm: int [1:344] 181 186 195 NA 193 190 181 195 193 190 ...
 $ body_mass_g   : int [1:344] 3750 3800 3250 NA 3450 3650 3625 4675 3475 4250 ...
 $ sex          : Factor w/ 2 levels "female","male": 2 1 1 NA 1 2 1 2 NA NA ...
 $ year         : int [1:344] 2007 2007 2007 2007 2007 2007 2007 2007 2007 2007 ...
```